

SESIÓN 1 • CURSO DESARROLLO ASISTIDO POR IA

FUNDAMENTOS DE IA GENERATIVA

¿Por qué los mejores ingenieros del mundo ya no trabajan solos?

LLMs · Tokens · Embeddings · Prompting · RAG

El Mundo ya Cambió

**5 min →
15 h**

AUTONOMÍA IA EN TAREAS COMPLEJAS CON +50% DE ÉXITO. EN 2023 ERAN 5 MINUTOS. CLAUDE OPUS 4 HOY: 15 HORAS. (METR, 2026)

55%

MÁS RÁPIDO. DESARROLLADORES CON GITHUB COPILOT COMPLETAN TAREAS UN 55% MÁS VELOZ. (GITHUB RESEARCH, 2022, N=95)

25%+

DEL NUEVO CÓDIGO DE GOOGLE ES GENERADO POR IA, REVISADO Y ACEPTADO POR INGENIEROS. (SUNDAR PICHAI, GOOGLE I/O, MAYO 2024)

1.5 años

VIDA ÚTIL DE UNA HABILIDAD EN INGENIERÍA DE SOFTWARE. EN OTRAS PROFESIONES DURA 5 AÑOS. ADAPTARSE ES SUPERVIVENCIA. (DELOITTE, 2017)

La Paradoja del Desarrollador

⚠ El riesgo de no aprender a dirigirla

- Amazon SEV-1, marzo 2026: código IA sin revisión senior causó caídas críticas en producción.
- Código *solo-IA*: 20 defectos por cada 1,000 líneas.
- Google DORA 2024: ingenieros que no revisan código IA pierden **25% de velocidad** por deuda técnica acumulada.
- HBR acuñó "*Brain Fry*": sobrecarga cognitiva de quienes no logran adaptarse al ritmo de la IA.

La demanda de talento experto no cae

- Google adquiere Wiz por \$32,000M — el mayor deal de seguridad e infraestructura de la historia.
- Modelo *Humano Senior + IA*: 8 defectos/1,000 líneas — el ratio más bajo de la industria.
- Amazon Q ahorró **4,500 años-desarrollador** en migraciones Java. (re:Invent 2023)
- La IA no reemplaza buenos ingenieros: reemplaza a los que no saben usarla.

“La persona que se comuniqué mejor será el programador más valioso del futuro. La nueva habilidad escasa es escribir especificaciones que capturen completamente tu intención y tus valores.”

— Sean Grove, OpenAI (AI Engineer Conference)

¿Es magia o matemática? Hoy entenderás por qué importa saberlo.

BLOQUE 1

CÓMO FUNCIONA LA IA

Sin fórmulas. Sin matrices.

La intuición que necesitas para trabajar con ella.

LA BASE DE TODO

¿Qué Hace Realmente un LLM?

Analogía: Imagina un **Stack Overflow** entrenado en toda la humanidad — libros, código, conversaciones, documentación — que en cada momento predice cuál es la siguiente palabra más probable dado el contexto que ya tiene.

No piensa. No razona. **Predice.** Esa predicción estadística, hecha a enorme escala, produce algo que *parece* inteligencia.



No razona
predice patrones



No valida lógica
modela probabilidades



Coherente ≠ Correcto
puede alucinar con seguridad

ACTIVIDAD A • LA IA QUE VE

Visión: Cuando la IA Analiza Imágenes

Herramienta: ChatGPT (GPT-4o) o Gemini 1.5 — adjunta una imagen en el chat

1

Sube una captura de pantalla de un error

Cualquier mensaje de error que tengas en tu pantalla ahora mismo. Escribe solo: *"¿Qué está fallando y cómo lo soluciono?"*

2

Sube la captura de una interfaz

Cualquier app o sistema que uses en tu trabajo. Pregunta: *"¿Qué problemas de usabilidad ves en esta pantalla?"*

3

Sube un diagrama o flujo en papel

Un esquema dibujado a mano, un diagrama de pizarra, un organigrama. Pide: *"Explícame este flujo y dime qué partes son ambiguas."*



La clave

Los LLMs modernos no solo leen texto — procesan imágenes, gráficos, capturas. Esto se llama capacidad **multimodal**.

Cómo Llegamos Hasta Aquí

Pre-2012

IA de Reglas

Sistemas expertos programados a mano. Si esto → entonces aquello. Frágil, costoso, no escalable.

2012

Las Máquinas Aprenden a Ver

AlexNet gana ImageNet por un margen histórico. GPUs + datos masivos cambian el juego para siempre.

2017

"Attention Is All You Need"

Google publica el paper del Transformer. La arquitectura que domina toda la IA moderna nace aquí.

2022

ChatGPT llega al trabajo

100M de usuarios en 2 meses. La IA generativa sale del laboratorio y entra al flujo de trabajo diario.

2025-26

Agentes con 15 horas de autonomía

Claude Code, Copilot Agent, Devin. La IA ya no autocompleta — ejecuta proyectos enteros.

LA ARQUITECTURA CLAVE

Transformer: La Intuición (Sin Fórmulas)

Antes, los modelos leían texto palabra por palabra. El Transformer escanea todo a la vez — como ver el stack trace completo de un vistazo en lugar de leerlo línea por línea.

La idea central: Atención

Cada palabra "mira" a todas las demás al mismo tiempo para entender el contexto.

"El banco estaba vacío..."

→ "...y me senté en él" → banco = asiento

→ "...cuando llegué al cajero" → banco = institución financiera

La atención resuelve ambigüedad sin leer en orden.



Paralelismo total

Procesa millones de palabras simultáneamente. Por eso puede entrenarse con toda internet.



Escala sin techo

Más datos + más cómputo = mejor resultado. GPT-3 → GPT-4 → Claude 4 lo demuestran.



Base de todo

GPT, Claude, Gemini, Llama — todos son Transformers. Una arquitectura domina la era.

ECONOMÍA DE LA IA

Tokens: La Unidad Económica

¿Qué es un token?

- **No es 1 palabra = 1 token.** Es un fragmento de texto — sílaba, palabra o símbolo.
- Espacios, tabulaciones y saltos de línea **también consumen tokens.**
- ⚠ **El español cuesta ~20% más tokens que el inglés** — impacto directo en proyectos latinoamericanos.
- El código fuente consume más tokens que lenguaje natural.

Por qué importa económicamente

- 10,000 llamadas/día · 2,000 tokens c/u:
GPT-4o → ~\$600/mes
GPT-4o mini → ~\$6/mes
- El output suele costar el **doblo que el input.**
- **Context Caching** reduce costos hasta un 75% en llamadas repetitivas.

Context Window: La RAM del LLM

Todo lo que la IA puede "ver" a la vez. Claude 4: 200K tokens $\approx$ una novela completa. Gemini 3: hasta 2 millones de tokens.

GPT-3 / GPT-4 base (2020–2023)

4k–8k

GPT-4 Turbo (2023)

128k

Claude 3.5 / Claude 4 · Gemini 1.5 (2024)

200k

Gemini 3 Pro / Claude Opus 4.7 (2025–2026)

1M–2M+

De procesar un breve ensayo a ingerir repositorios de código completos de un solo vistazo.

BÚSQUEDA SEMÁNTICA

Embeddings: Búsqueda que Entiende el Significado

Analogía: Los embeddings mapean palabras a puntos en un espacio. Palabras similares quedan cerca. "error" $\approx$ "falla" $\approx$ "bug" $\rightarrow$ mismo vecindario.

Una búsqueda tradicional no encontraría "falla" si buscas "error". Los embeddings sí. Entienden **significado**, no solo coincidencia de caracteres.

Aplicaciones prácticas

- Búsqueda semántica en documentación
- Clasificar tickets de soporte por categoría
- Encontrar contenido similar aunque use palabras distintas
- Base técnica de la arquitectura RAG

¿Por qué importa en este curso?

- Es la tecnología que hace que RAG funcione
- Permite que Claude Code "entienda" tu repositorio
- Habilita búsqueda inteligente en bases de datos propias
- +30-50% precisión con modelos especializados por dominio

ACTIVIDAD B • LA GEOMETRÍA DEL SIGNIFICADO

Embeddings en 3D: Ver el Significado con tus Ojos

Herramienta: projector.tensorflow.org — visualizador interactivo de embeddings reales

1

Busca palabras de tecnología

En el panel de búsqueda escribe: `software`, luego `algorithm`, luego `function`. Observa qué palabras aparecen como vecinas en el espacio 3D.

2

Compara palabras semánticamente distintas

Busca `king` y luego `queen`. Nota la distancia entre ellas. Luego busca `car` — está lejos de ambas. La distancia **es** el significado.

3

Rota el espacio 3D

Arrastra para rotar la visualización. Observa cómo palabras relacionadas forman **clusters** — grupos de conceptos similares agrupados en el espacio.



Lo que acabas de ver

Esto es lo que ocurre internamente cuando la IA "entiende" un texto. RAG, búsqueda semántica y embeddings operan exactamente sobre esta geometría — en cientos de dimensiones, no solo 3.

ACTIVIDAD C · TOKENS EN VIVO

Radiografía de la Tokenización

Herramienta: platform.openai.com/tokenizer

1

Prueba en inglés

Escribe: We sat down at the bank of the river — cuenta los tokens.

2

Prueba en español

Escribe: Nos sentamos a la orilla del río — ¿cuántos más que en inglés?

3

Prueba con código

Pega: `print("Hola mundo")` — ¿cuántos tokens consume una sola línea?



La conclusión

El idioma y el formato impactan directamente en el costo de tu integración IA. Escribir prompts limpios no es solo claridad — es economía.

ACTIVIDAD D • IA COMO ANALISTA

Análisis de Datos: Tu Analista en 8 Minutos

Herramienta: **ChatGPT Plus** (Advanced Data Analysis) — sube un archivo CSV o Excel

1

Sube un CSV de datos reales

Métricas de ventas, registros de soporte, tiempos de respuesta, encuestas — cualquier dato que tengas en Excel o CSV.

2

Pide un análisis exploratorio

Escribe: *"Encuentra las 3 anomalías más preocupantes en estos datos y explícame qué podrían significar."*

3

Pide una visualización

Escribe: *"Genera un gráfico de tendencia mensual y dime si ves correlación entre las columnas X e Y."*

4

Pide el resumen ejecutivo

Escribe: *"Resume estos hallazgos en 5 puntos para presentar a un comité directivo que no conoce los datos."*

BLOQUE 2

CÓMO HABLARLE A LA IA

El prompt es tu nueva interfaz de trabajo.

La diferencia entre 20 defectos y 8 está en cómo le pides.

ACTIVIDAD E · ENERGIZANTE VISUAL

Generación de Imágenes: Assets sin Diseñador

Herramienta: ChatGPT con DALL-E 3 o ideogram.ai (gratuito)

1

Genera un ícono de producto

Prompt: *"Ícono flat design para una app de gestión de proyectos tecnológicos, estilo minimalista, colores azul y gris, fondo transparente."*

2

Genera una imagen para presentación

Prompt: *"Imagen conceptual de transformación digital para una empresa de servicios, estilo corporativo moderno, sin texto, formato panorámico."*

3

Refina con iteración

Pide variaciones: *"Misma imagen pero en tonos más oscuros, sin personas, más abstracto."* La IA recuerda el contexto anterior.



El principio que aplica a todo

La calidad del output es proporcional a la especificidad del input. Esto también aplica a texto, análisis y código.

EL NUEVO FLUJO DEL PROFESIONAL TECH

IA en Tu Ciclo de Trabajo



Desarrollo y código

Copilotos como GitHub Copilot y Claude Code. Generación de funciones, navegación de repositorios, refactorización.



Análisis e informes

CSV, PDFs, dashboards. La IA encuentra patrones, anomalías y genera resúmenes ejecutivos en minutos.



Diseño y comunicación

Assets visuales, presentaciones, documentación técnica. Del brief a la imagen o el texto en segundos.



Audio y reuniones

Transcripción automática, resúmenes de reuniones, extracción de puntos de acción. Tu reunión de 1 hora en 5 bullets.

Prompt Sin Estructura vs Con S.C.T.C.

✗ Prompt sin estructura

"Analiza este reporte y dame lo más importante"

- ¿Para quién? ¿Para qué decisión? ¿Con qué profundidad?
- Respuesta genérica e impredecible
- Sin formato → difícil de usar directamente
- Múltiples retries hasta obtener algo útil

✓ Prompt con S.C.T.C.

S: "Analista senior de tecnología"

C: "Comité directivo que evalúa migración cloud"

T: "Resume los 3 riesgos críticos y su impacto económico"

C: "Máximo 5 bullets. Sin tecnicismos. Formato ejecutivo."

- Output accionable en el primer intento
- Tono y profundidad calibrados a la audiencia
- Formato listo para usar directamente

FRAMEWORK CENTRAL DEL CURSO

Patrón S.C.T.C.



S — System

Define la persona y expertise. *"Actúa como consultor senior de transformación digital con experiencia en banca latinoamericana."*



C — Context

Antecedentes del problema. *"Evaluamos migrar nuestra infraestructura on-premise a cloud. Tenemos 200 servidores y 50 aplicaciones críticas."*



T — Task

Orden imperativa clara. *"Genera una lista de preguntas que deberíamos hacerle al proveedor cloud antes de firmar el contrato."*



C — Constraints

Límites y formato. *"Máximo 10 preguntas. Ordenadas de mayor a menor riesgo. Sin jerga técnica profunda. Solo texto plano."*

EJEMPLO REAL • EVALUACIÓN DE PROVEEDOR

S.C.T.C. Aplicado: Análisis de Propuesta

S

System — La identidad

"Actúa como arquitecto de soluciones cloud con 10 años evaluando propuestas de Microsoft Azure, AWS y Google Cloud para empresas financieras."

C

Context — El ambiente

"Somos una empresa de 500 empleados en el sector financiero. Recibimos una propuesta de migración a Azure de 18 meses con un costo de \$2.5M."

T

Task — La orden

"Analiza la propuesta adjunta e identifica los riesgos que el proveedor no menciona explícitamente y las cláusulas que debería negociar."

C

Constraints — Los límites

"Separa en: riesgos técnicos, riesgos contractuales y riesgos de continuidad. Formato de tabla. Sin recomendaciones de otros proveedores."

Chain-of-Thought: Para Decisiones Complejas

Pedirle a la IA que piense en voz alta antes de responder mejora drásticamente la calidad en problemas de razonamiento.

¿Cómo se activa?

”Antes de responder, piensa paso a paso:

1. ¿Qué información tengo vs. qué me falta?
2. ¿Cuáles son los supuestos de esta propuesta?
3. ¿Qué escenarios adversos no se están considerando?

Luego dame tu análisis final.”



17% → 78%

Mejora en precisión de razonamiento con CoT vs sin él. (Wei et al., 2022, Google Brain)



No abuses

CoT consume más tokens y tiempo.
Para tareas simples no es necesario
— calibra según complejidad.



Úsalo para

Evaluación de propuestas,
diagnóstico de problemas complejos,
decisiones con múltiples variables.

ACTIVIDAD F • PROMPT EN VIVO

S.C.T.C. y Chain-of-Thought en Práctica

Herramienta: claude.ai o gemini.google.com

1

El prompt vago

Escribe: *"Resume las ventajas del trabajo remoto"* — observa el resultado. ¿Para quién es? ¿Qué decisión apoya?

2

Aplica S.C.T.C.

Define el Sistema (consultora RR.HH.), el Contexto (empresa tech de 300 personas evaluando política híbrida), la Tarea (pros y contras para el liderazgo) y los Constraints (tabla, sin opiniones, máx. 6 puntos por lado).

3

Agrega Chain-of-Thought

Añade: *"Antes de responder, identifica los supuestos que estás usando y las variables que no tengo datos para medir."*



Reflexión del grupo

¿Cuánto cambió la calidad entre el primer y tercer prompt? ¿Qué tan reutilizable es el S.C.T.C. que escribiste?

ACTIVIDAD G · VISIÓN AVANZADA

Análisis de Diagrama: La IA Como Revisor Técnico

Herramienta: ChatGPT (GPT-4o) o Claude (claude.ai) — adjunta imagen en el chat

1**Sube un diagrama de arquitectura o red**

Una topología de infraestructura, un mapa de sistemas, un organigrama tecnológico — cualquier diagrama de tu entorno de trabajo.

2**Pregunta por puntos de fallo**

Escribe: *"¿Cuáles son los puntos únicos de fallo en esta arquitectura y qué pasaría si cada uno falla?"*

3**Pide la versión para gerencia**

Escribe: *"Explicame este diagrama como si tuviera que presentarlo a un comité directivo no técnico en 3 minutos."*

4**Pide mejoras**

Escribe: *"¿Qué componentes agregarías para hacer este diseño más resiliente siguiendo buenas prácticas de la industria?"*

BLOQUE 3

Por Qué el LLM Solo No Alcanza para Producción



Desconoce tu información privada

El LLM fue entrenado con datos públicos. Tu documentación interna, procesos propietarios, políticas — no existen para él.



Sin acceso dinámico

Su conocimiento tiene fecha de corte. No sabe de tu última release, el incidente del mes pasado, ni el precio de hoy.



Fine-tuning es costoso

Reentrenar un modelo para que aprenda tu dominio cuesta millones y demora semanas. No es opción para la mayoría.



87% usa RAG o tools

El 87% de proyectos IA en producción usa Retrieval-Augmented Generation o tool-calling. (a16z State of AI, 2024)

RAG en 60 Segundos

Retrieval-Augmented Generation = darle al LLM el contexto exacto que necesita, justo cuando lo necesita.



Resultado: respuestas precisas sobre *tu* dominio, sin alucinaciones, sin reentrenamiento.

ACTIVIDAD H · RAG SIMPLIFICADO

Análisis de Reporte Técnico: RAG en la Práctica

Herramienta: **ChatGPT** (sube PDF) o **Gemini 1.5** — esto es RAG gestionado sin infraestructura

1**Sube un documento real**

Un reporte de Gartner, una propuesta de proveedor, un white paper, una RFP, o cualquier documento técnico extenso que debas evaluar.

2**Pregunta por los riesgos ocultos**

Escribe: *"¿Cuáles son los 3 riesgos principales que este documento no menciona explícitamente pero que están implícitos en los supuestos?"*

3**Pide el resumen ejecutivo**

Escribe: *"Resume este documento en 5 bullets para presentar a un comité directivo que no tiene contexto técnico."*

4**Genera las preguntas para el proveedor**

Escribe: *"¿Qué preguntas debería hacerle al proveedor antes de firmar, ordenadas de mayor a menor impacto contractual?"*

ACTIVIDAD I · EL TIEMPO QUE NO RECUPERAS

Audio y Transcripción: Tu Reunión de 1 Hora en 5 Minutos

Herramienta: Gemini 1.5 Pro (sube audio) · Otter.ai · o Microsoft Copilot en Teams

1

Graba o sube una reunión

Usa un clip de reunión grabada (2-3 minutos), o graba en vivo una conversación simulada sobre un proyecto tecnológico.

2

Pide los puntos de acción

Escribe: *"Extrae todos los puntos de acción mencionados, con el responsable y la fecha comprometida cuando estén disponibles."*

3

Convierte a formato de ticket

Escribe: *"Convierte cada punto de acción en un ticket Jira con campos: Título, Descripción, Prioridad estimada y Criterios de aceptación."*



El impacto real

El tiempo promedio documentando una reunión de 1 hora: **45 minutos**. Con IA: **5 minutos de revisión**.

Realidad vs Expectativa

Lo que la IA NO reemplaza

- Arquitectura y decisiones de diseño estratégico
- Diagnóstico profundo con contexto del negocio
- Seguridad: validar, auditar, responsabilizarse
- Criterio para juzgar si el output generado es correcto
- La responsabilidad ante clientes, equipos y sistemas

Lo que la IA Sí amplifica

- Velocidad de prototipado: días → horas
- Análisis de documentos extensos: horas → minutos
- Generación de assets visuales sin diseñador
- Documentación de reuniones y procesos
- Onboarding a sistemas y contextos nuevos

Paradoja de Jevons: código más barato → demanda x4.5 → code churn subió de 10% a 22%. Los buenos profesionales son más necesarios que nunca.

CIERRE ACCIONABLE

Lo que Cambia Desde Mañana

1**Elige una actividad de hoy y repítela esta semana**

Visión, análisis de datos, audio, diagrama — elige la que más dolor te resuelve. Úsala en una situación real antes de la próxima sesión.

2**Aplica S.C.T.C. en tu próxima consulta a la IA**

Toma el prompt que normalmente escribirías y añade Sistema, Contexto y Constraints. Compara la calidad del primer output vs antes.

3**Mide y trae el dato a la próxima sesión**

¿Cuánto tardabas en esa tarea antes? ¿Cuánto tardas ahora? El dato que traigas es tu evidencia de valor.

4**En la próxima sesión**

Integraremos IA en el ciclo de vida del software completo: Frontend → Backend → Base de datos → Calidad → Documentación.

BDG - BUSINESS DEVELOPMENT GROUP

¿CUÁL ACTIVIDAD DE HOY CAMBIARÍA ALGO CONCRETO EN TU TRABAJO?

Preguntas y Respuestas · Discusión abierta